


Fundamentos de IA Generativa



Objetivo

Desvendar os segredos por trás dos modelos generativos, entender seus limites e potencialidades, comparar arquiteturas e criar soluções reais. Dominar a IA generativa não apenas para acompanhar a revolução tecnológica, mas para **estar na linha de frente da criação de aplicações inteligentes e produtivas que estão moldando o futuro das grandes empresas.**



Natan Pasquarelli Freitas

Gerente de engenharia no Itaú

Founder do Eureklabs.com

Criador do Natanpf.com

A mais de 20 anos trabalhando com TI

A mais de anos 8 em cargos de liderança



Natan Pasquarelli Freitas



@natanpf



@eureklabs



Agenda

- ⊕ **Introdução à IA Generativa**
- ⊕ **Modelos de Linguagem (LLMs)**
- ⊕ **Geração de Respostas**
- ⊕ **Arquiteturas e Tipos de Modelos**
- ⊕ **Embeddings e Representações Vetoriais**
- ⊕ **Estratégias de Uso**



Você está em um mundo onde o código não é mais o fim, mas o meio. O quanto você realmente entende o que está por trás da IA que começa a fazer parte do seu dia a dia? Você está pronto para transformar essa ferramenta em um diferencial estratégico, ou vai ficar para trás enquanto outros escrevem o futuro?



O Novo Cenário da Tecnologia

Enquanto conversamos, novos modelos generativos estão sendo treinados, novas APIs lançadas, novas formas de construir produtos surgindo. Não é mais sobre *fazer mais rápido*, mas *fazer diferente*.

Do Velho para o Novo Perfil:

Se antes ser um tech lead significava liderar times com foco em eficiência e entrega, agora também significa **liderar com inteligência**, entendendo o que a IA pode fazer **por você, pelo seu time e pelo seu produto**.

“Você está apenas usando as ferramentas ou está entendendo os fundamentos que moldam essas ferramentas?”



A virada de chave

A dependência de soluções prontas cria uma falsa sensação de segurança. Confiar cegamente em ferramentas como Copilot ou ChatGPT pode resolver problemas imediatos, mas limita a capacidade de adaptação e inovação. Quando surgem novas necessidades, ou quando o contexto muda, quem não entende os fundamentos fica para trás.

Aqueles que conhecem os bastidores e os mecanismos da IA generativa não apenas utilizam ferramentas, mas são capazes de criar, adaptar e liderar soluções.



Os riscos de continuar na zona de conforto

A evolução da IA é inevitável. O mercado está mudando rapidamente, e os profissionais que não acompanham ficam obsoletos. A diferença entre quem lidera e quem segue está na disposição de sair da zona de conforto e mergulhar no entendimento do novo.

A pergunta que precisa ser feita não é se você está usando IA, mas se você está pronto para continuar relevante à medida que o mercado se transforma.

Aqueles que compreendem os fundamentos da IA generativa estarão à frente, tomando decisões técnicas mais seguras, explorando possibilidades mais amplas e entregando valor de maneira diferenciada.



IA Generativa não é apenas uma tendência, mas uma transformação que já está moldando a forma como produtos são desenvolvidos e times são geridos.

A pergunta final que deixo para você é: você quer ser a pessoa que espera pela solução ou aquela que constrói a solução?

Durante este curso, você terá a oportunidade de entender, adaptar e liderar com IA generativa. O convite é para que você saia da zona de conforto e comece a construir o conhecimento necessário para se tornar uma liderança técnica de verdade na nova era da tecnologia.



A IA generativa representa um dos avanços mais disruptivos na área de tecnologia nas últimas décadas. Com o crescimento do volume de dados e do poder computacional, a capacidade de construir modelos que **não apenas reconhecem padrões, mas criam novos conteúdos**, abriu espaço para aplicações antes consideradas impossíveis.



Enquanto a IA tradicional se concentra na análise e na previsão com base em dados conhecidos, a IA generativa inaugura um novo paradigma: **o de criar a partir do aprendizado**, seja para gerar texto, imagens, sons, código ou mesmo vídeos.



Definição e conceito fundamental

A Inteligência Artificial Generativa (IA generativa) é um campo da IA que se concentra no desenvolvimento de modelos capazes de produzir novos dados que não existiam antes, aprendendo padrões e estruturas subjacentes a partir de dados existentes.



Definição e conceito fundamental

Esses sistemas não apenas classificam ou identificam, como na IA tradicional, mas conseguem criar saídas originais que ainda mantêm coerência e contexto com os dados de treinamento.



Definição e conceito fundamental

Texto: um modelo de IA pode gerar uma nova notícia ou um capítulo de livro que nunca foi escrito, mantendo o estilo e a coerência.

Imagem: uma IA pode criar uma pintura ou ilustração original, imitando o estilo de um artista famoso.

Código: modelos como Copilot geram trechos completos de código funcional.

Áudio e Música: sistemas criam novas músicas ou locuções que soam naturais.



Definição e conceito fundamental

A IA generativa combina conceitos de aprendizado profundo (deep learning), modelos probabilísticos e algoritmos sofisticados de atenção, permitindo que ela crie novos exemplos baseados no que aprendeu.



Comparação com a IA Tradicional e Estatística

A IA tradicional, especialmente aquela supervisionada, foca na classificação ou regressão com base em dados conhecidos. O modelo é treinado com exemplos rotulados (inputs e outputs conhecidos) e, depois, recebe novos dados para prever a saída mais provável.





Características principais:

Previsão ou decisão baseada em padrões observados.

Requer dados rotulados e consistentes.

Tarefas típicas: detecção de fraude, classificação de e-mails (spam vs. legítimo), reconhecimento de imagem (identificar se é um gato ou cachorro), previsão de demanda.

Limitação: não cria nada novo, apenas generaliza o que já foi aprendido.





IA Generativa:

A IA generativa é treinada para entender a estrutura e os padrões internos dos dados de entrada e, a partir disso, gerar novos exemplos que seguem as mesmas regras implícitas.



Características principais:

Produz saídas originais, como texto, imagens e sons.

Treinada em grandes volumes de dados sem necessidade de rótulos explícitos (muitas vezes é auto-supervisionada ou não supervisionada).

Tarefas típicas: criação de conteúdo original, síntese de dados, geração de imagens realistas, escrita automatizada, geração de código, tradução automática sofisticada.

Capacidade de lidar com contexto longo e criar coerência (graças a arquiteturas como Transformer).



Analogia prática:

IA tradicional: é como um aluno que faz provas de múltipla escolha, escolhe a melhor resposta entre opções baseadas no que já aprendeu.

IA generativa: é como um escritor que, com base na leitura de centenas de livros, escreve uma nova história original com começo, meio e fim.




Como a IA Generativa Aprende?

A IA generativa não mapeia entradas para saídas fixas, como na IA tradicional.

Ela modela probabilidades complexas presentes nos dados.

Funciona como um artista que aprende estilos e composições para criar algo novo e original.




Como a IA Generativa Aprende?

Ao ser treinada com muitos dados, a IA generativa aprende padrões e estruturas ocultas.

Ela desenvolve uma intuição para prever quais elementos fazem sentido juntos.

Cria um mapa probabilístico do universo do dado.

Usa esse mapa para explorar novas combinações e gerar exemplos inéditos, mas coerentes com o que aprendeu.




Abstração

O modelo funciona como um cartógrafo do conhecimento.

Observa montanhas, rios e cidades (os dados).

Aprende regras para prever onde novas montanhas e rios podem surgir e como as cidades se conectam.

Cria um novo mapa com áreas inéditas, mas coerentes e plausíveis.




Modelos autorregressivos (ex: GPT)

Esses modelos escrevem texto palavra por palavra, usando o contexto das palavras anteriores.

Cada palavra influencia a escolha da próxima.

O processo continua até que o conteúdo esteja completo.

Funciona como um escritor que mantém coerência e fluxo na narrativa.



A Origem da Ideia de IA

A ideia de máquinas inteligentes existe desde a Antiguidade.

A IA moderna surgiu na metade do século XX, com foco em simular a mente humana por algoritmos.



A Origem da Ideia de IA

Em 1950, Alan Turing publicou o artigo “Computing Machinery and Intelligence”.

Propôs a pergunta: “**As máquinas podem pensar?**”

Introduziu o **Teste de Turing**, que avalia se uma máquina consegue se passar por um humano em uma conversa.



A Origem da Ideia de IA

O objetivo passou de criar máquinas “mecânicas” para **simular processos cognitivos humanos com algoritmos e computadores.**




Décadas de 1950–1960: Primeiros Modelos

Em 1956, a Conferência de Dartmouth marcou o nascimento da IA.

Pesquisadores discutiram como simular a inteligência humana em computadores.

A década de 1950 foi o início dos experimentos em aprendizado automático.



Décadas de 1950–1960: Primeiros Modelos

Em 1958, Frank Rosenblatt criou o Perceptron, inspirado em neurônios.

Foi a primeira rede neural a aprender com exemplos.

Representou um marco inicial no aprendizado de máquinas.



Décadas de 1950–1960: Primeiros Modelos

Anos 1960: surgem sistemas de IA baseados em regras, como DENDRAL e MYCIN.

Usavam lógica “SE-ENTÃO”, mas eram limitados por dependerem de regras manuais.



Décadas de 1950–1960: Primeiros Modelos

Entretanto, nessa época, o entusiasmo era tão grande que muitos acreditavam que máquinas “pensantes” seriam realidade em poucas décadas. Mas isso logo se mostrou otimista demais.



Décadas de 1970–1980: O “Inverno da IA”

Sistemas da época não resolviam problemas complexos.

Isso levou ao primeiro inverno da IA, com queda no interesse e nos investimentos.



Décadas de 1970–1980: O “Inverno da IA”

Em 1982, John Hopfield propôs as redes neurais recorrentes.

Representaram um avanço rumo a comportamentos mais humanos na IA.



Décadas de 1970–1980: O “Inverno da IA”

Modelos como HMMs e Naive Bayes ganharam destaque.

Introduziram uma abordagem estatística para lidar com incertezas.



1990–2000: A Estatística Toma Conta

Anos 1990: aumento de dados e poder computacional fortaleceu métodos estatísticos.

Naive Bayes se destacou como classificador baseado em probabilidade condicional.



1990–2000: A Estatística Toma Conta

Cadeias de Markov e HMMs – que modelam sequências, permitindo prever a próxima palavra em um texto, a próxima ação em um processo, ou mesmo transições em jogos e música.



1990–2000: A Estatística Toma Conta

Mesmo menos “inteligentes”, os modelos estatísticos eram eficientes.



2010–2014: A Era do Aprendizado

Profundo

Com Big Data e GPUs, o deep learning ganhou força.

Técnicas antes limitadas puderam ser aplicadas em larga escala.

Redes profundas foram usadas em imagem, fala e tradução automática.




2010–2014: A Era do Aprendizado

Profundo

Em 2014, surgiram as GANs, de Ian Goodfellow.


Dois modelos competem para gerar dados realistas.

Iniciaram a era da IA generativa moderna.



2017: A Revolução dos Transformers


Em 2017, o artigo “Attention Is All You Need”, de Vaswani et al., apresentou o Transformer, uma arquitetura que mudou radicalmente o campo do processamento de linguagem natural.



2017: A Revolução dos Transformers

Transformers usam atenção para entender melhor o contexto.


Deram origem ao BERT (2018) e ao GPT, modelos chave da IA moderna.



2020 até Hoje: A Era da IA Generativa


Desde 2020, modelos generativos se expandiram com Transformers.

GPT-3/4 geram textos, DALL·E cria imagens e Stable Diffusion popularizou arte digital.



2020 até Hoje: A Era da IA Generativa

Música, modelagem 3D, e simulações em tempo real. Hoje, a IA está presente em aplicações práticas no cotidiano – de assistentes virtuais a sistemas de recomendação, passando por diagnósticos médicos e criação de conteúdo digital.





FLUID
LANGUAGE

SIMPLE
RULES

Antes de entendermos onde estamos com os LLMs modernos (como o GPT-4), é fundamental entender de onde viemos. A trajetória da IA generativa mostra uma progressão clara: de **modelos baseados em estatísticas simples**, que operavam com regras rígidas e conhecimento limitado, até chegarmos a **modelos capazes de gerar linguagem com fluidez, coerência e criatividade**.

Limitações principais:

Baixa capacidade de capturar **dependências de longo prazo**

Frases geradas tendem a ser **fragmentadas, repetitivas ou incoerentes**

Crescimento exponencial do vocabulário com o aumento de “n” torna o modelo difícil de escalar

Não há real “compreensão” semântica: é puro padrão estatístico



Limitações principais:

Por exemplo:

Exemplo:

Frase com modelo 2-grama:


“Gato preto dorme sofá gato preto dorme sofá...”

Se o modelo aprendeu que a sequência “gato preto” ocorre com frequência, ele vai gerar “preto” sempre que vir “gato”.



O avanço em relação aos n-gramas

Os **(HMMs)** surgiram como uma evolução natural dos modelos n-grama. Enquanto os n-gramas se limitavam a capturar dependências explícitas entre palavras com base em frequências locais, os HMMs introduziram uma ideia fundamental: **a existência de uma estrutura interna que governa a geração de observações, mas que não é diretamente visível.**



O que é um HMM?

Um HMM é um modelo estatístico que descreve um sistema com:

Estados ocultos (hidden states)

Observações (outputs).

Transições de estado

Distribuição de emissão



Funcionamento de um HMM

Elementos centrais do modelo:

Conjunto de estados ocultos

Conjunto de observações possíveis

Matriz de transição entre estados

Matriz de emissão



Algoritmos principais

Forward-Backward

Viterbi

Baum-Welch (EM)



Aplicações clássicas dos HMMs

Reconhecimento de fala

Biologia computacional



Limitações dos HMMs

Os HMMs assumem que a **próxima observação depende apenas do estado atual**, e que o estado atual depende apenas do anterior.



Limitações dos HMMs

Para treinar bem os HMMs, geralmente são necessários **conjuntos de dados rotulados**, especialmente nas tarefas supervisionadas.



Virada de chave da IA moderna

Durante as décadas de 1980 e 1990, a inteligência artificial evoluía lentamente. Havia limitações claras de hardware e dados. Os modelos probabilísticos, como os n-gramas e os Hidden Markov Models (HMMs), eram usados com sucesso em diversas aplicações, mas apresentavam problemas graves de escalabilidade e expressividade.



O que são Redes Neurais Profundas (DNNs)

Redes neurais são compostas por camadas de neurônios artificiais, que simulam o comportamento de neurônios biológicos. A entrada passa por essas camadas sucessivas, onde é transformada, combinada e reinterpretada, até gerar uma saída.



Aplicação em linguagem natural

Linguagem não é um dado que possa ser diretamente manipulado por uma rede neural. Para isso, usamos embeddings.



Redes Neurais Feedforward

A rede feedforward é a estrutura neural mais simples. Ela segue um fluxo de dados unidirecional:

Recebe uma entrada (ex: sequência de palavras convertida em embeddings).



Limitações das redes feedforward

Contexto limitado

Elas só conseguem olhar para um número fixo de palavras anteriores (ex: 3 ou 5).

Isso impede o modelo de entender contextos mais longos, como dependências que atravessam frases ou parágrafos inteiros.



Limitações das redes feedforward

Ordem da sequência

A arquitetura feedforward não é sensível à posição das palavras na sequência.



O desafio da sequência

Diferentemente das redes feedforward, que processam blocos fixos de entrada, é preciso um modelo que saiba guardar memória do que foi processado anteriormente.



Limitações das RNNs

Desvanecimento do gradiente

Explosão do gradiente

Contexto limitado

Baixa paralelização



A evolução: LSTM e GRU

Para contornar essas limitações, surgiram arquiteturas aprimoradas que adicionaram controle sobre a memória.

LSTM:

Porta de entrada > Porta de esquecimento > Porta de saída

GRU:

Porta de entrada/esquecimento > Porta de saída



O ponto de ruptura

Dificuldade em capturar dependências de longo prazo.

Incapacidade de paralelizar o processamento de sequências

Criamos o conceito de Atenção



O que é autoatenção (self-attention) ?

O mecanismo de autoatenção permite que cada palavra da sequência de entrada, observe todas as outras palavras da mesma sequência.

Como funciona um Transformer?

A arquitetura Transformer é composta por blocos empilháveis de dois componentes principais:

Camadas de autoatenção

Camadas feedforward

Positional Encoding



Por que os modelos não usam palavras diretamente?

Na linguagem natural temos alguns problemas:

- Altamente variável
- Vocabulário necessário seria imenso e pouco generalizável.
- Diferentes línguas
- Erros de escrita
- Novas palavras



O que são LLMs?


Linguagem de larga escala

Treinados com bilhões de parâmetros e enormes volumes de texto

Esses modelos são baseados na arquitetura Transformer.

LLMs operam com:

- Autoatenção
- Embeddings
- Feedforward + camadas empilhadas



Capacidades dos LLMs

Geração de texto

Compreensão semântica

Capacidade emergente: Raciocínio e generalização

Modelos GPT

Generative

Pre-trained

Transformer

Modelos BERT

Foco em compreender texto, não gerar.



GANs – A necessidade de geração visual realista

Gerador e discriminador

- Com o tempo, ambos vão melhorando

VAEs – Geração com estrutura (Variational Autoencoders)

Aprendizado de representações compactas e úteis dos dados.



Arquitetura Interna dos LLMs

Camadas de Atenção Multi-Head (Multi-Head Attention)

Single-Head Attention

$$\text{Atenção}(Q, K, V) = \text{softmax}(Q \times K^T / \sqrt{d_k}) \times V$$

Multi-Head Attention

Divide os vetores Q, K e V em subespaços menores.



Position-wise Feedforward Layers

- $\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$
- W_1, W_2 : matrizes de peso
- b_1, b_2 : vetores de viés
- $\max(0, \cdot)$: função ReLU para introduzir não-linearidade

$$(\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2)$$



O que é Positional Encoding?

É um **vetor adicional** que informa a **posição** da palavra na sequência. Esse vetor é **somado** ao vetor da palavra (word embedding) antes de ser processado pelo Transformer.

Seno e Cosseno (Positional Encoding Fixo)

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$$



Learned Positional Embeddings (Aprendidos)

É como se, ao longo do tempo, o modelo desenvolvesse intuição própria sobre onde cada palavra está baseada em contexto.

Qual é melhor ?



Por que precisamos deles?

Balancear e estabilizar as informações entre camadas

Dificuldade de treinar.

Instabilidade no fluxo de informações entre camadas

Fórmula: $\text{Output} = x + f(x)$



O que é Pré-Treinamento?

- Primeira fase do aprendizado de um modelo de linguagem.
- Ele aprende sem rótulos humanos

Por que isso é importante?


- O custo de rotular dados manualmente é alto.

Como o modelo aprende?

- CLM
- MLM


Qual é a função de perda usada?

- Cross-Entropy Loss



O que é MLM ?

- Palavras faltando (mascaradas)
- Usado em modelos como BERT.
- Palavras são mascaradas aleatoriamente.
- Contexto bidirecional.
- Não é necessário nenhum rótulo externo.



O que é Fine-Tuning supervisionado?


- Especializamos para uma tarefa específica com exemplos rotulados, ou seja, com respostas certas e erradas já conhecidas.

Como funciona?

- Escolha da tarefa específica
- Montagem de um dataset supervisionado
- Treinamento adicional

Cuidados e limitações

- Overfitting
- Viés nos dados
- Custo
- Atualização constante




O que é Instrução + RLHF?

- Fine-tuning supervisionado com instruções humanas.


Etapas de um Pipeline com RLHF

- Supervised Fine-Tuning (SFT)
- Treinamento do Reward Model
- Reinforcement Learning (RL)



Técnicas de Otimização para Grandes Modelos

- LoRA (Low-Rank Adaptation)
- Quantização (INT4, INT8)
- Mixture of Experts (MoE)
- P-tuning e Prefix-tuning



Factualidade e Alucinação nos LLMs

Esses modelos não “sabem” o que é verdade. Eles aprendem padrões estatísticos da linguagem

- Alucinação factual
- Alucinação de citações ou fontes
- Alucinação estrutural
- Alucinação contextual



O contexto é limitado por um número máximo de tokens que o modelo consegue “enxergar” e considerar de uma vez.

- Diluição de Relevância
- Perda de Foco no Final ou no Começo
- Custo Computacional

Estratégias para contornar

- Chunking inteligente
- Resumos hierárquicos
- Prompt explícito com instrução de foco



Dificuldades para raciocínio lógico e simbólico

- Inferir consequências a partir de premissas
- Seguir múltiplas etapas encadeadas
- Lidar com negações, quantificadores, contradições e implicações

Por que os LLMs têm dificuldade com isso?

- Base probabilística, não simbólica
- Falta de consistência entre etapas
- Ausência de mecanismos explícitos de memória e verificação




Não aprendem novas informações após o treinamento.

Modelos como o GPT-4 não aprendem com interações individuais.

Contexto da Conversa.

Se o modelo foi treinado em 2023, ele não sabe nada de 2024.

Retrieval-Augmented Generation (RAG)



- **Compreender como os LLMs geram respostas**
- **Controlar estilo e comportamento das saídas**
- **Aplicar isso em contextos reais**



A decisão de qual token gerar pode ser controlada por estratégias de amostragem, que influenciam se o modelo será:

- Criativo ou conservador
- Preciso ou surpreendente
- Fluente ou técnico



Modelos de linguagem como GPT não geram texto de forma fixa.

Top-k sampling é uma técnica de geração de texto de base fixa.

Top-p sampling é uma técnica de base percentual.

1.céu (prob. 0.35)

2.horizonte (0.25)

3.mar (0.15)

4.campo (0.10)

5.deserto (0.08)

6.... (outros tokens ignorados)



Arquiteturas de LLMs

Encoder-only

- Contexto: Por que surgiu essa arquitetura?
- O que é Encoder-only?
- Como funciona na prática?
- Quando usar ?
- Quais as variações ?



Decoder-only (Apenas Decodificador)

Causal Self-Attention (atenção autoregressiva)

O cachorro correu rápido

	O	cachorro	correu	rápido
O	✓	✓	✓	✓
cachorro	✓	✓	✓	✓
correu	✓	✓	✓	✓
rápido	✓	✓	✓	✓

	O	cachorro	correu	rápido
O	✓	0	0	0
cachorro	✓	✓	0	0
correu	✓	✓	✓	0
rápido	✓	✓	✓	✓




Três grandes chaves que permitem transformar modelos poderosos em soluções úteis:

- Engenharia de prompts
- Recuperação aumentada por geração
- Fine-tuning.

Prompt Engineering é a prática de criar instruções textuais específicas

- Eficiência sem re-treinamento
- Aumento de precisão e consistência
- Economia de tokens e custo
- Facilita o controle e teste



Zero-shot Prompting

Você dá apenas uma instrução direta, sem exemplos anteriores.

Few-shot Prompting

Você inclui alguns exemplos (input + output) antes de fazer a pergunta real.

Chain-of-thought Prompting (COT)


Essa técnica induz o modelo a explicar seu raciocínio passo a passo antes de responder.

Role-based Prompting

Você instrui o modelo a assumir um papel específico.

Instruction Tuning (via Prompt)

Molda explicitamente o comportamento do modelo via comandos claros e bem definidos.



Ponto de partida


Revisitamos a história da IA

- 2 Grama
- Markov
- Redes Neurais
- RNNs
- Transformers


Fundamentos técnicos

- LLMs
- GenAI moderna

GANs / VAEs




- Camadas de Atenção Multi-Head
- Feedforward Position-wise
- Codificação Posicional
- LayerNorm + Conexões Residuais
- Pré-treinamento com CLM e MLM
- Fine-tuning supervisionado
- RLHF



Eficiência e Otimização

- LoRA – Low-Rank Adaptation
- Quantização – INT8, INT4
- Mixture of Experts (MoE)



Desafios dos LLMs

Alucinação de conteúdo

Geração de Respostas e Controle

- Temperatura
- Top-k
- Top-p (nucleus sampling)
- Context windows e truncamentos

Estudamos três grandes arquiteturas

- Encoder-only
- Decoder-only
- Encoder-decoder

